

大语言模型本地部署体验与横向对比测试报告

2453356 李昂

一、项目公开访问链接

项目仓库地址：<https://github.com/1608472939/LLM-Test-Homework>

二、模型本地部署过程展示

1. 部署环境说明

本项目在魔搭平台（ModelScope）申请了 PAI-DSW 免费配套云计算资源，采用 8 核 32GB 的纯 CPU 环境进行本地推理部署。全程在 Conda 虚拟环境中配置了 PyTorch 及所需基础依赖。

2. 模型下载与加载

本项目分别拉取了 Qwen-7B-Chat（通义千问）和 ChatGLM3-6B（清华智谱）两个开源大语言模型。以下为拉取模型数据时的过程截图：

```
git clone https://www.modelscope.cn/qwen/Qwen-7B-Chat.git
正克隆到 'Qwen-7B-Chat'...
remote: Enumerating objects: 554, done.
remote: Counting objects: 100% (56/56), done.
remote: Compressing objects: 100% (30/30), done.
remote: Total 554 (delta 30), reused 49 (delta 26), pack-reused 498
接收对象中: 100% (554/554), 16.47 MiB | 31.46 MiB/s, 完成.
处理 delta 中: 100% (294/294), 完成.
过滤内容: 100% (8/8), 14.38 GiB | 155.45 MiB/s, 完成.

git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git
正克隆到 'chatglm3-6b'...
remote: Enumerating objects: 147, done.
remote: Counting objects: 100% (25/25), done.
remote: Compressing objects: 100% (24/24), done.
remote: Total 147 (delta 11), reused 1 (delta 0), pack-reused 122
接收对象中: 100% (147/147), 78.33 KiB | 541.00 KiB/s, 完成.
处理 delta 中: 100% (63/63), 完成.
过滤内容: 100% (15/15), 23.26 GiB | 150.61 MiB/s, 完成.
(qwen_env) root@dsw-1910399-5b467b4c95-p8zs5:/mnt/data#
```

三、问答测试与结果记录

为了测试模型对中文复杂语义、多义词及网络用语的理解能力，本项目采用 5 个典型的“中文语境陷阱”段子对两个模型进行了分别提问，结果如下：

1. 测试案例一

请说出以下两句话区别在哪里？ 1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少。

Qwen-7B-Chat 回答：

```
请说出以下两句话区别在哪里？ 1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少

这两句话的语境和含义不同。

1. 冬天：能穿多少穿多少”这句话是在描述冬天的寒冷气候，强调在冬季需要尽可能多地穿上衣服以保暖。它传达的是对寒冷天气的应对策略，是一种实用性的建议。

2. 夏天：能穿多少穿多少”这句话则是在描述夏天的炎热气候，强调在夏季需要尽可能少地穿上衣服以散热。它传达的是对高温天气的应对策略，也是一种实用性的建议。

因此，尽管这两句话中的“能穿多少”表达的意思相同，但是它们所处的环境和目的都是不同的，所以它们的区别在于使用的季节和语境。</endoftext>
```

ChatGLM3-6B 回答：

```
ChatGLM3的回答:
这两句话的区别在于，1是关于冬天如何穿衣的指导，而2是关于夏天如何穿衣的指导。尽管两句话都包含了“能穿多少穿多少”，但它们所针对的季节不同，因此内容上有所区别。
```

2. 测试案例二

请说出以下两句话区别在哪里？单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上。

Qwen-7B-Chat 回答：

请说出以下两句话区别在哪里？单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上自己。

这两个句子之间的区别在于表达的含义和语气。第一个句子“单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上自己”是一种客观描述事实的语句，语气比较冷静。而第二个句子“单身狗产生的原因有两个，一是谁都不喜欢我，二是我自己不喜欢我自己”则更倾向于一种主观感受的表达，语气更加激烈和带有自嘲的味道。同时，第二个句子还加入了一些个人情感色彩，暗示了说话者的自卑感和孤独感。因此，这两个句子在语义和语气上有明显的差异。

ChatGLM3-6B 回答：

这两句话的区别在于表述方式不同，但它们的本质是相同的。第一句话“单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上”表达了一个问题的两个可能原因，即单身狗的原因可能是自己看不上别人，也可能是别人看不上自己。第二句话“单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上”用“一是”和“二是”进行了概括，突出了问题的两个可能原因。这两句话的主要区别在于表述方式，第一句更详细，而第二句更简洁。

3. 测试案例三

他知道我知道你知道他不知道吗？这句话里，到底谁不知道

Qwen-7B-Chat 回答：

3. 他知道我知道你知道他不知道吗？这句话里，到底谁不知道？是不是所有的人都知道了呢？不管怎样，我们还是先来看看这句话的意思吧。

正确的顺序应该是：他知道我知道你不知道他不知道。因为按照逻辑推理，如果你知道的和我都知道的事情，那他一定也知道，否则他就无法跟我们交流了。所以，正确的顺序应该是“他知道我知道你不知道他不知道”。这样，就表达了所有人的状态都被包含了进去。

如果我们要按照“知道知道知道不知道”的顺序来排列的话，那就变成了一个悖论，因为这意味着“他知道他知道他知道他知道我不知道他知道他知道”，这是一种非常不可能的情况，也就是说，所有的人都知道了他们不应该知道的事情，这显然是不合理的。

所以，正确的方式是按照逻辑关系来排列句子，而不是随意改变句子的顺序。通过这种方式，我们可以更好地理解和表达复杂的思想和概念。

ChatGLM3-6B 回答：

ChatGLM3的回答：
这句话是一个典型的悖论，叫作“他知道我知道你知道他不知道”。在这个问题中，有两个人，我们称他们为A和B。

A知道B知道他知道不知道的事情。而B知道A知道他知道不知道的事情。但是，如果B知道A知道这个事实，那么A也应该知道B知道这个事实。这样，A就不再是一个不知道的人了。

所以，这个问题中，真正不知道的是A。他知道B知道他知道不知道的事情，而B也确实知道A知道他知道不知道的事情。但是，由于A知道了这个事实，他不再是一个不知道的人了。

4. 测试案例四

明明明明明白白白喜欢他，可她就是不。这句话里，明明和白白谁喜欢谁？

Qwen-7B-Chat 回答：

明明明明明白白白喜欢他，可她就是不。这句话里，明明和白白谁喜欢谁？ A. 明明喜欢白白 B. 白白喜欢明明

B

ChatGLM3-6B 回答：

ChatGLM3的回答：
根据这句话的描述，明明明白白白喜欢他，但白白并没有说出口。因此，可以得出结论，白白喜欢明明。

5. 测试案例五

领导：你这是什么意思？ 小明：没什么意思。意思意思。 领导：你这就不够意思了。 小明：小意思，小意思。领导：你这人真有意思。 小明：其实也没有别的意思。 领导：那我就不好意思了。 小明：是我不好意思。请问：以上“意思”分别是什么意思。

Qwen-7B-Chat 回答：

领导：你这是什么意思？ 小明：没什么意思。意思意思。 领导：你这就不够意思了。 小明：小意思，小意思。领导：你这人真有意思。 小明：其实也没有别的意思。 领导：那我就不好意思了。 小明：是我不好意思。请问：以上“意思”分别是什么意思。

以上对话中的“意思”有以下几种解释：

- 本意：原意，本来的意思。
- 言外之意：说话时隐藏在字面意义背后的真实意图或想法。
- 意思意思：表示无关紧要、随便、不认真等意思。

注意：小明的“意思”表达方式可能是因为紧张或者调皮而产生的，不一定是有意恶意的。

ChatGLM3-6B 回答：

情平慢里加载完毕，GLM正在疯狂思考中

ChatGLM3的回答：

1. 领导：你这是什么意思？ - 意思：指言语、行为、动作等所表达的意义、内涵或目的。
2. 小明：没什么意思。意思意思。 - 意思：指言语沦为废话、空洞无物、没有意义。
3. 领导：你这就不够意思了。 - 意思：指不满、不满意，表示对某种行为或态度的不认同。
4. 小明：小意思，小意思。 - 意思：指 token、纪念品等微不足道的价值。
5. 领导：你这人真有意思。 - 意思：表示对某人的言语、行为、个性等方面表示赞赏、认可。
6. 小明：其实也没有别的意思。 - 意思：指没有其他特殊的意义或目的。
7. 领导：我就不好意思了。 - 意思：表示对某种要求或请求的拒绝、避免。

四、大语言模型横向对比分析

通过对 Qwen-7B-Chat 和 ChatGLM3-6B 两个模型在五个经典中文复杂语境下的输出结果进行横向比对，可以总结出它们在语义理解、逻辑推理及指令遵循上的不同特质。

1. 常识语境解析与双关语处理能力

在关于冬天和夏天“能穿多少穿多少”的常识语境测试中，两个模型均表现优异，能够精准识别出“多穿御寒”与“少穿散热”的反向含义。Qwen 采用了非常严谨的分点结构化排版，而 ChatGLM3 的表述则更加直接精炼。

然而，在处理“单身狗谁都看不上”这一双关语陷阱时，两者的表现拉开了差距。Qwen 出现了严重的指令读取错误，自行将原题篡改为了“谁都不喜欢我”来强行解释主客观差异；ChatGLM3 忠实于原提示词，成功指出了“自己看不上别人”与“别人看不上自己”的两层含义，但在最终总结时将其归结为排版啰嗦与简洁的区别，并未完全点破该段子的核心幽默感。

2. 极端中文分词与深层逻辑嵌套能力

在汉字极度重复的“明明明明白白白白喜欢他”测试中，原本极易导致模型分词器崩溃。但令人惊艳的是，两个模型均完美跨越了专有名词与副词的混淆陷阱，准确地进行了断句，并一致得出了“白白喜欢明明”的正确结论，展现了国产大模型在中文基础预训练上的扎实功底。

但在面临深层嵌套的逻辑推理测试，即“他知道我知道你知道他不知道吗”的绕口令时，两个模型集体陷入了逻辑死胡同。Qwen 主观认定原句逻辑不通，试图篡改语序来强行合理化；ChatGLM3 虽然试图建立角色模型进行推导，但在中途发生了逻辑断裂，给出了自相矛盾的结论。这表明多层逻辑嵌套依然是目前端侧小参数模型的共同软肋。

3. 多轮上下文与多义词消歧能力

在经典的“意思意思”多义词测试中，两者拉开了最大的理解代差。Qwen 仅仅脱离具体语境，输出了该词在字典中的三种死板释义，缺乏结合上下文的具体分析。与之形成鲜明对比的是，ChatGLM3 展现出了极其强大的上下文情景理解能力，它将对话精准拆分为七个步骤，并准确剖析了每一处“意思”背后的潜台词（如：言语的内涵、不满、微不足道的价值、赞赏等）。这说明在模拟真人互动、揣摩人类真实意图方面，ChatGLM3 具有压倒性的优势。

测试维度	测试案例内容	Qwen-7B-Chat 表现	ChatGLM3-6B 表现	优势模型
常识语境	冬夏“穿多少”差异	准确理解，排版呈结构化，条理清晰	准确理解，表述直接精炼	平局
双关语意	单身狗“看不上”	产生幻觉，擅自篡改原题提示词	忠于原题，能分辨出主客观两层含义	ChatGLM3
分词断句	“明明与白白”陷阱	完美断句，准确输出选项结果	完美断句，给出准确的推导结论	平局
逻辑嵌套	“知道不知道”推理	逻辑崩塌，试图修改原句语序	逻辑断裂，推导过程出现自相矛盾	均不足

多义消歧	上下文“意思”含义	敷衍作答，仅给出脱离语境的字典释义	表现惊艳，精准拆解并释义了全部7处潜台词	ChatGLM3
------	-----------	-------------------	----------------------	----------